


Analyzing the Latent Input Space of LLMs for Systematic Prompt Testing


COINSE @ KAIST
Somin Kim, Shin Yoo



ERC'26 Summer Workshop

Motivation

LLM-based Application 테스트의 어려움



LLM기반 어플리케이션


1. 제약 없는 입력 공간
정해진 형식이나 경계가 없어, 어떤 토큰 조합이든
입력이 될 수 있음
2. LLM 실행 비용
 - API 호출 / GPU 연산 비용
 - 응답까지 걸리는 시간
3. Oracle 비용
 - Manual한 라벨링
 - LLM-as-a-judge로 평가

Background: Clotho


LLM의 은닉상태를 분석해 실패 가능성이 높은 입력을 선별하는 테스트 기반 적절성 평가 기법

LLM 인풋 (프롬프트 템플릿 + 가변 입력)


Identify the topic of the following task: Input



생성된 답변토큰들



Activation Vector 공간에서
태스크에 따라 명확한 클러스터가 형성




올바른/잘못된 결과를 생성하는 입력의 구분

Background: Clotho

LLM의 은닉상태를 분석해 실패 가능성이 높은 입력을 선별하는 테스트 기반 적절성 평가 기법

Pass 할 가능성이 높은 인풋



Gaussian Mixture Model

- Gaussian Mixture Model를 활용한 은닉 벡터 분포 모델링
- 목표: 성공하는 입력 공간을 GMM으로 모델링하고, 이 입력공간에 존재할 확률 (Likelihood)을 Adequacy로 추정


$$\mathcal{L}_{\text{pass}}(x) = p_{\theta}(h(x)), \quad h(x): \text{hidden state representation (LIH)}$$

$$\text{LSA}(x) = -\log p_{\theta}(h(x))$$

Additional axis on Clotho

실패하는 입력을 찾는 것만으로는 충분하지 않다



Clotho는 입력의 실패 가능성을 기반으로 입력들을 정렬하지만,
상위에 랭킹된 입력들은 (Failure Pattern)가 모두 비슷한 유형일 수 있음



개발자들이 프롬프트를 수정하거나
모델을 finetune할때 필요한 정보 제공

Failing Inputs show Latent Structure




실패하는 입력들의 내부 은닉상태 관찰



- Failing Inputs으로 학습한 GMM의 예측성능이 Passing GMM이랑 비슷함
 - Passing, Failing 둘다 사용하는 Dual-Guidance가 성능이 가장 높았음
- Failing하는 입력들은 단순한 noise가 아니라 모델 내부에서 관찰 가능한 분포를 형성

Failing Inputs show Latent Structure

실패하는 입력들의 내부 은닉상태 관찰



Case Study: JSON-FIX

- Normalized Mutual Information (NMI) = 0.503
- 잠재 공간에서 자동으로 나뉘어진 컴포넌트가 실제 해석가능한 실패 유형과 대응됨 (완벽한 1:1 매핑은 아님)

Future Direction: Latent-Guided Test Input Synthesis

내부 은닉상태를 활용한 테스트 입력 생성

은닉상태를 자연어로 직접 복원하는 대신, 후보 candidate 입력들을 생성하고 Latent objective으로 선택/진화 시켜 입력들을 합성한다.

1. 후보 입력 생성
 - a. 기존 input들의 interpolation
 - b. Genetic Algorithm 사용한 Search
2. 잠재공간 투영
3. 테스트 셋 구성
 - a. Failure Pattern 근접성 기반
 - b. Boundary Input 구성

